



دانشکده مهندسی کامپیوتر

بازیابی پیشرفته اطلاعات

مدرس: دکتر بیگی

شماره گروه: ۵

تهیه کنندگان: نیما جمالی - سپهر فعلی - سینا کاظمی

گزارش فاز دوم پروژه

فهرست مطالب

۳	ساختن فضای برداری برای دسته‌بندها
۳	پیش پردازش و تنظیم فیلدهای اولیه
۴	پیاده‌سازی فضای برداری tf-idf به روش ntn
۵	ذخیره‌سازی فضای برداری
۶	پیاده‌سازی دسته‌بندها
۶	Naïve Bayes
۸	k-NN
۹	SVM
۱۰	Random Forest
۱۱	محاسبه‌ی Validation Set
۱۲	محاسبه‌ی بهترین پارامتر برای الگوریتم k-NN
۱۳	محاسبه‌ی بهترین پارامتر برای الگوریتم SVM
۱۴	بهبود سیستم بازیابی فاز اول پروژه
۱۵	تابع اجماع نظر دسته‌بندها برای تعیین برجسب هر مستند
۱۵	جستجو بر اساس دسته
۱۷	ارزیابی نهایی
۱۷	پیاده‌سازی تابع find_metric
۱۷	معیارهای ارزیابی برای Naïve Bayes
۱۸	معیارهای ارزیابی برای k-NN
۱۸	معیارهای ارزیابی برای SVM
۱۸	معیارهای ارزیابی برای Random Forest
۱۹	نتیجه‌گیری نهایی معیارهای ارزیابی

۲۰	نحوه‌ی تقسیم وظایف
۲۰	نیما جمالی
۲۰	سپهر فعلی
۲۰	سینا کاظمی
۲۱	مراجع

ساختن فضای برداری برای دسته‌بندها

در این بخش که در واقع بخش آغازین کار است، ابتدا کلاس جدیدی به نام Classifier تعریف می‌کنیم و constructor آن را تکمیل می‌کنیم. همچنین به کلاس IRSystem که در فاز اول پروژه طراحی شده بود، متدی برای محاسبه‌ی فضای برداری اسناد به روش tf-idf اضافه می‌کنیم. در ادامه به شرح پیاده‌سازی این بخش می‌پردازیم.

پیش پردازش و تنظیم فیلدهای اولیه

کلاس Classifier یک path را به عنوان ورودی دریافت می‌کند. این path مشخص می‌کند که دسته‌بندی قرار است بر روی چه فایلی اعمال شود. سپس از کلاس IRSystem برای پیش‌پردازش مستندات موجود در train.csv استفاده می‌کنیم. تابع call_prepare و call_create_positional را برای این مجموعه مستندات صدا می‌زنیم تا نمایه‌ی positional ساخته شود. از آنجا که می‌خواهیم مستندات موجود در path را هم در این مجموعه درج کنیم، سائز مجموعه‌ی آموزش را در متغیری به نام train_size نگه می‌داریم. سپس مستندات موجود در path را درج می‌کنیم. y_test را هم که برای محاسبه‌ی معیارهای ارزیابی استفاده می‌شود، تنها در صورتی تعریف می‌کنیم که path همان test.csv باشد. در این صورت y_test برابر با لیستی خواهد بود که مقادیر آن، به ترتیب برابر با مقادیر ستون views در داده‌ی آزمون است.

همچنین دو متغیر train_vector_space و vector_space هر دو فضای برداری هستند که مورد اول برای محاسبه‌ی دسته‌بندهای SVM و Random Forest ایجاد شده و مورد دوم برای محاسبه‌ی دسته‌بند k-NN استفاده شده‌است که در ادامه آنها را نیز توضیح می‌دهیم.

```
class Classifier:
    def __init__(self, path):
        self.train_ir_sys = IRSystem(["description", "title", "data/train.csv", None])
        self.train_ir_sys.call_prepare("english", False)
        self.train_ir_sys.call_create_positional("english")
        self.train_size = len(self.train_ir_sys.structured_documents["english"])
        self.train_ir_sys.csv_insert(path, "english")
        self.train_vector_space = self.create_vector_matrix(self.train_ir_sys, "english")
        self.y_train = self.csv_views("data/train.csv")

        self.vector_space = self.train_ir_sys.use_ntn("english")

        self.y_test = None
        self.knn_classifier = None
        self.svm_classifier = None
        self.naive_bayes_classifier = None
        self.random_forest_classifier = None
        if path == "data/test.csv":
            self.y_test = self.csv_views("data/test.csv")

    def csv_views(self, path):
        df = pd.read_csv(path, usecols=["views"])
        result = []
        for i in range(len(df)):
            result += [df.iloc[i]["views"]]
        return result
```

تصویر ۱: طراحی اولیه کلاس Classifier و تنظیم فیلدهای آن

پیاده‌سازی فضای برداری tf-idf به روش ntn

در این بخش، ابتدا در کلاس IRSystem متدی با نام ntn طراحی کردیم که یک doc_id و زبان آن را ورودی می‌گیرد. سپس یک دیکشنری به نام result می‌سازد که کلیدهای آن، ترم‌های آن مستند و مقادیر آن، حاصل عبارت $tf_{term, doc} \times idf_{term}$ برای هر کلید است. این تابع توسط تابعی به نام use_ntn صدا زده می‌شود. این تابع به ازای تمام مستندات، دیکشنری گفته شده را محاسبه کرده و بر می‌گرداند.

```
def ntn(self, doc_id, lang):
    doc = []
    for part in self.structured_documents[lang][doc_id]:
        for word in part:
            doc += [word]
    doc_dict = Counter(doc)
    result = dict()
    for term in doc_dict.keys():
        if term not in result.keys():
            p = self.positional_index[lang][term]
            df = len(p.keys()) - 1
            idf = math.log10(len(self.structured_documents[lang])) / df
            result[term] = doc_dict[term] * idf
    return result

def use_ntn(self, lang):
    vectors = []
    for doc_id in range(len(self.structured_documents[lang])):
        vectors += [self.ntn(doc_id, lang)]
```

تصویر ۲: طراحی توابع ntn و use_ntn

برای طراحی فضای برداری که الگوریتم‌های کتابخانه‌های آماده برای SVM و Random Forest بتوانند آن را پیاده کنند، نیاز به ماتریسی از ndarray داریم و نمی‌توان از دیکشنری استفاده کرد. به همین دلیل نیاز داریم برای هر ترم مستقل در کل دیکشنری (train + test) یک عدد داشته باشیم که به صورت یک‌تا بین آنها رابطه وجود داشته باشد. برای این کار تابع token_to_number را طراحی می‌کنیم که به هر token عدد خاصی نسبت می‌دهد. این عدد خاص از صفر تا 1 - len(terms) می‌تواند باشد.

سپس برای ساختن ماتریسی از ndarray، تابع create_vector_space را صدا می‌زنیم که ابتدا ماتریسی از صفر تولید می‌کند که تعداد سطرهای آن برابر با تعداد مستندات و تعداد ستون‌های آن برابر با تعداد کل ترم‌هاست. در نهایت با صدا زدن use_ntn برای هر مستند، برای هر ترم در آن مستند از تابع token_to_number استفاده می‌کنیم

و وزن مربوط به آن ترم در مستند را در ماتریس به روز رسانی می کنیم. در نهایت این ماتریس در فیلدی به نام `train_vector_space` ذخیره می شود.

```
def token_to_number(self, ir_sys, lang):
    return {token: ind for ind, token in enumerate(ir_sys.positional_index[lang].keys())}

def create_vector_matrix(self, ir_sys, lang):
    vector = np.zeros([len(ir_sys.structured_documents[lang]), len(ir_sys.positional_index[lang].keys())])
    tokenized_vector = ir_sys.use_ntn(lang)
    for doc_id in range(len(tokenized_vector)):
        for term in tokenized_vector[doc_id].keys():
            vector[doc_id][self.token_to_number(ir_sys, lang)[term]] = tokenized_vector[doc_id][term]
    return vector
```

تصویر ۳: طراحی توابع مورد نیاز برای ساخت فضای برداری به روش ماتریسی

ذخیره سازی فضای برداری

فضای برداری ایجاد شده در قسمت قبل بسیار بزرگ است، زیرا تعداد ترم های دیکشنری چیزی در حدود ۱۲۰۰۰ است! لذا هر نمونه از Classifier که ساخته می شود، زمان زیادی می گیرد. برای همین تصمیم گرفتیم دو نمونه ای که از کلاس Classifier می سازیم (یک نمونه برای `test.csv` و یک نمونه برای `ted_talks.csv`) را ذخیره کنیم، البته این ذخیره سازی بعد از تکمیل سایر متدهای کلاس Classifier انجام می گیرد. با دستور `create` می توانیم یک نمونه ایجاد کنیم و با دستور `save`، آن نمونه را ذخیره کنیم. نمونه ی این دستورات را می توان در این [تست](#) مشاهده کرد.

پیاده‌سازی دسته‌بندها

در این بخش توابع دسته‌بندی را طراحی می‌کنیم. همچنین توابع مورد نیاز برای محاسبه‌ی بهترین پارامتر را طراحی می‌کنیم. در ادامه به شرح پیاده‌سازی این توابع می‌پردازیم. دقت شود که از کل مجموعه داده‌ی train.csv برای آموزش دسته‌بندها استفاده شده‌است.

Naïve Bayes

یکی از راه‌های پیش‌بینی کردن گروه و دسته یک شی (در این پروژه، همان مستند)، الگوریتم Naive-Bayes است. این الگوریتم، تعداد نسبتاً زیادی داده تحت عنوان داده‌ی آموزش دریافت می‌کند که گروه هریک از این داده‌ها مشخص است و با پردازش آن، به نوعی ویژگی‌های هر گروه معلوم می‌شود. بدین‌شکل که اگر x رخ داده باشد، احتمال این که به گروه A مرتبط باشد بیشتر است یا گروه B. برای پیاده‌سازی این الگوریتم از سه تابع بهره بردیم:

- تابع `naive_bayes_train(self, flag_counter, words, lang)`: این تابع، قسمت آموزش الگوریتم را انجام

می‌دهد و درواقع پایه و اساس کارکرد الگوریتم را شامل می‌شود. اما نحوه کار:

متغیر `flag_counter` یک دیکشنری ۴عضوی است، متشکل از مقادیر زیر:

- تعداد مستنداتی که عضو گروه ۱ هستند. (`positive_docs`)
- تعداد مستنداتی که عضو گروه ۱- هستند. (`negative_docs`)
- تعداد ترم‌های غیریکتا در مستندات گروه ۱ (`positive_terms`)
- تعداد ترم‌های غیریکتا در مستندات گروه ۱- (`negative_terms`)

متغیر `words` یک دیکشنری بزرگ از ترم‌های موجود در مجموعه‌ی مستندات داده‌های آموزش است. هر عضو آن، خود یک دیکشنری ۲عضوی است که از مقادیر زیر تشکیل شده‌است.

- تعداد تکرار کلمه موردنظر در مستندات گروه ۱ (`words[term]["positive"]`)
- تعداد تکرار کلمه موردنظر در مستندات گروه ۱- (`words[term]["negative"]`)

این دو متغیر، در این تابع و با پردازش داده‌های آموزش که قبلاً پیش‌پردازش شده‌اند و در متغیری از کلاس `ir_system` به نام `structured_documents[lang]` ذخیره شده‌اند، مقداردهی و تکمیل می‌شوند تا در ادامه مورد استفاده قرار گیرند.

- تابع `naive_bayes_test(self, flag_counter, words, lang)`: این تابع، قسمت آزمایش الگوریتم را انجام

می‌دهد و درواقع، خروجی الگوریتم است. یعنی با استفاده از نتایج برآمده از پردازش داده‌های آموزش در

تابع `naive_bayes_train`، گروه‌های داده‌های آزمایش را پیش‌بینی می‌کند. اما نحوه‌ی کار چگونه است:

به ازای هر مستند ورودی، به روش زیر می توانیم گروه مربوط به آن را حدس بزنیم.

$$C_{MAP} = \operatorname{argmax}_{c \in C} \left[\log P(c) + \sum_{1 \leq k \leq n_d} \log P(t_k | c) \right]$$

$$P(t|c) = \frac{T_{ct} + 1}{(\sum_{t' \in V} T_{ct'}) + B}, \quad P(c) = \frac{\text{len}(C = c)}{\text{len}(C = c) + \text{Len}(C \neq c)}$$

پیاده سازی این روابط در کد به این صورت است که

- برای محاسبه T_{ct} به `words[t][c]` رجوع می کنیم.
- برای محاسبه $\sum_{t' \in V} T_{ct'}$ به `flag_counter[c_terms]` رجوع می کنیم.
- مقدار B برابر با تعداد ترم های یکتای داده های آزمون است.
- برای محاسبه $\text{len}(C = c)$ نیز به `flag_counter[c_docs]` مراجعه می کنیم.

در نهایت، نتیجه حدس های خود را در لیستی به ساین داده های آزمایش به نام `y_predicted` می ریزیم که این متغیر، خروجی تابع خواهد بود.

- تابع `naive_bayes(self, lang)`: این تابع فرآیند اجرای الگوریتم را کنترل می کند. یعنی دیکشنری های `flag_counter` و `words` را `initialize` می کند، سپس ابتدا تابع آموزش یعنی `naive_bayes_train` و سپس تابع آزمایش یعنی `naive_bayes_test` را صدا می کند و خروجی، یعنی `y_predicted` را برمی گرداند.

```
def naive_bayes(self, lang):
    flag_counter = {"positive_docs": 0, "negative_docs": 0, "positive_terms": 0, "negative_terms": 0}
    words = dict()
    self.naive_bayes_train(flag_counter, words, lang)
    y_predicted = self.naive_bayes_test(flag_counter, words, lang)
    return y_predicted

def naive_bayes_train(self, flag_counter, words, lang):
    for docID in range(self.train_size):
        if self.y_train[docID] == 1:
            flag = "positive"
            flag_counter["positive_docs"] += 1
        else:
            flag = "negative"
            flag_counter["negative_docs"] += 1

        for col in range(2):
            for word in self.train_ir_sys.structured_documents[lang][docID][col]:
                if word not in words.keys():
                    words[word] = {"positive": 0, "negative": 0}
                words[word][flag] += 1
                flag_counter[str(flag + "_terms")] += 1

def naive_bayes_test(self, flag_counter, words, lang):
    y_predicted = []
    p_positive_doc = flag_counter["positive_docs"] / self.train_size
    p_negative_doc = 1 - p_positive_doc
    for docID in range(len(self.train_ir_sys.structured_documents[lang]) - self.train_size):
        p_positive = 0
        p_negative = 0
        for col in range(2):
            for word in self.train_ir_sys.structured_documents[lang][self.train_size + docID][col]:
                if word in words.keys():
                    p_positive += math.log(
                        (words[word]["positive"] + 1) / (flag_counter["positive_terms"] + len(words)))
                    p_negative += math.log(
                        (words[word]["negative"] + 1) / (flag_counter["negative_terms"] + len(words)))
                else: # new word in test doc
                    p_positive += math.log(1 / (flag_counter["positive_terms"] + len(words)))
                    p_negative += math.log(1 / (flag_counter["negative_terms"] + len(words)))
            if math.log(p_positive_doc) + p_positive >= math.log(p_negative_doc) + p_negative:
                y_predicted.append(1)
            else:
                y_predicted.append(-1)
    return y_predicted
```

تصویر ۴: توابع مورد نیاز برای دسته بند Naïve Bayes

در کنسول می توان با دستور naive_bayes test، برچسب هایی که این دسته بند برای مجموعه ی تست می زند مشاهده کرد.

k-NN

دسته بند k-NN بسته به پارامتر k ورودی، k نزدیک ترین همسایه ی مستند داده شده را در مجموعه ی آموزش می یابد و با توجه به اکثریت برچسب ها در میان آن k مستند، برچسب مستند آزمایشی را محاسبه می کند.

به این منظور تابعی به نام knn طراحی می کنیم که مجموعه ی مستندات آموزش و برچسب های آنها، مجموعه ی مستندات آزمایش و پارامتر k را ورودی می گیرد. می توانستیم از فضای برداری که در بخش [پیاده سازی فضای برداری](#) [tf-idf به روش ntn](#) توضیح داده شد، استفاده کنیم، اما دسته بندی با آن روش به علت این که صفرهای زیادی را بدون آن که در محاسبه نیاز شوند، نگه می داریم و در واقع ماتریس sparse است، زمان زیادی می گیرد.

به همین علت فضای برداری جدیدی با نام vector_space (یا به عبارت بهتر knn_vector_space) ایجاد می کنیم که برای محاسبه ی آن، تابع use_ntn را صدا می زنیم. سپس باید فاصله ی دو مستند را حساب کنیم. برای این کار تابعی به نام two_doc_distance تعریف می کنیم که دو مستند را از فضای برداری vector_space می گیرد و فاصله ی آنها را محاسبه می کند. برای محاسبه ی k نزدیک ترین همسایه، باید فاصله ی هر مستند آزمایش با هر مستند آموزشی را داشته باشیم که این کار از طریق تابع documents_distances انجام می شود و خروجی آن ماتریسی است که سطرهای آن، مستندات آموزش و ستون های آن، مستندات آزمایش است.

```
def two_doc_distance(self, first, second, doc1, doc2):
    list1 = first[doc1].keys()
    list2 = second[doc2].keys()
    intersect = set(list1) & set(list2)
    delta = set(list1) ^ set(list2)
    result = 0
    for term in intersect:
        result += ((first[doc1][term] - second[doc2][term]) ** 2)
    for term in delta:
        if term in first[doc1].keys():
            result += ((first[doc1][term]) ** 2)
        else:
            result += ((second[doc2][term]) ** 2)
    return math.sqrt(result)

def documents_distances(self, first, second):
    result = []
    for i in range(len(first)):
        result += [[]]
        for j in range(len(second)):
            result[i] += [self.two_doc_distance(first, second, i, j)]
    return result
```

تصویر ۵: توابع محاسبه کننده ی فاصله ی مستندات

در تابع knn، ابتدا این ماتریس محاسبه می‌شود. سپس هر ستون را که متناظر یک مجموعه‌ی تست است، به صورت صعودی مرتب کرده و k تایی اول را برای هر ستون انتخاب می‌کنیم. سپس برچسب هر یک از این k مستند را بررسی می‌کنیم. اگر تعداد ۱‌ها بیشتر باشد، برچسب مستند آزمایش هم ۱ و در غیر این صورت ۰ خواهد بود.

```
def knn(self, x_train, y_train, x_test, k):
    dists = np.array(self.documents_distances(x_train, x_test))
    y_pred = []
    for doc_id in range(len(x_test)):
        test_dist = dists[:, doc_id]
        sorted_nearest_docs = [s[0] for s in sorted(enumerate(test_dist), key=lambda a: a[1])]
        top_k = sorted_nearest_docs[:k]
        pos_views, neg_views = 0, 0
        for train_id in top_k:
            if y_train[train_id] == 1:
                pos_views += 1
            else:
                neg_views += 1
        if pos_views > neg_views:
            y_pred += [1]
        else:
            y_pred += [-1]
    return y_pred
```

تصویر ۶: تابع محاسبه‌ی دسته‌بند k-NN

در کنسول هم می‌توان با دستور k test knn برچسب‌هایی که دسته‌بند k-NN به داده‌های تست می‌زند، مشاهده کرد. دقت شود که k یک عدد طبیعی است که کاربر ورودی می‌دهد.

SVM

بردارهای پشتیبان به زبان ساده، مجموعه‌ای از نقاط در فضای n بعدی داده‌ها هستند که مرز دسته‌ها را مشخص می‌کنند و دسته‌بندی داده‌ها بر اساس آنها انجام می‌شود و با جابه‌جایی یکی از آنها خروجی دسته‌بندی ممکن است تغییر کند. در این قسمت از کتابخانه‌ی یادگیری ماشین پایتون به نام sklearn استفاده کردیم که تمام کرنل‌ها و توابع نگاشت را به صورت آماده دارد. ۳ تابع SVC, NuSVC, LinearSVC وظیفه اصلی دسته‌بندی را در این کتابخانه دارند که ما از SVC که مخفف Support Vector Classifier است استفاده می‌کنیم.

ورودی‌های این تابع کرنل مورد استفاده و پارامتر C است. کرنل را **گاوسی** (rbf) در نظر گرفتیم و پارامتر C را از ورودی می‌گیریم. با استفاده از کرنل گاوسی، داده‌ها را به فضای بی‌نهایت بعدی نگاشت می‌کنیم و در آن فضا دسته‌بندی را انجام می‌دهیم. پارامتر C نیز در واقع میزان اهمیت به اشتباه دسته‌بندی شدن داده‌ها و فاصله‌ی خط جداساز از Support Vectorها را مشخص می‌کند.

در کنسول می‌توان با وارد کردن دستور svm test c که پارامتری است که کاربر ورودی می‌دهد، برچسب‌های خروجی دسته‌بند SVM را برای مجموعه‌ی تست مشاهده کرد.

```
def svm(self, x_train, y_train, x_test, c_parameter):
    model = SVC(kernel='rbf', C=c_parameter)
    model.fit(x_train, y_train)
    self.svm_classifier = model
    y_pred = model.predict(x_test)
    return y_pred
```

تصویر ۷: دسته‌بند SVM

Random Forest

الگوریتم جنگل تصادفی یا همان Random Forest یک الگوریتم ترکیبی (ensemble) است که از درخت‌های تصمیم بهره می‌گیرد.

الگوریتم درخت تصمیم (decision trees) می‌تواند به راحتی عملیات طبقه‌بندی را بر روی داده‌ها انجام دهد. حال در الگوریتم جنگل تصادفی از چندین درخت تصمیم (برای مثال ۱۰۰ درخت تصمیم) استفاده می‌شود. در واقع مجموعه‌ای از درخت‌های تصمیم با هم یک جنگل را تولید می‌کنند و این جنگل می‌تواند تصمیم‌های بهتری را نسبت به یک درخت اتخاذ نماید.

در الگوریتم جنگل تصادفی به هر کدام از درخت‌ها، زیرمجموعه‌ای از داده‌ها تزریق می‌شود. برای مثال اگر مجموعه داده دارای ۲۵۵۰ سطر باشد و ۱۰ ستون داشته باشد، الگوریتم جنگل تصادفی به هر کدام از درخت‌ها ۱۰۰ سطر و ۵ ستون - که به طور تصادفی انتخاب شده‌اند و زیرمجموعه‌ای از مجموعه‌ی داده‌ها هست - می‌دهد. این درخت‌ها با همین دیتاست زیرمجموعه، می‌توانند تصمیم بگیرند و مدل دسته‌بند خود را بسازند.

برای پیاده‌سازی این بخش، از کتابخانه‌ی sklearn استفاده می‌کنیم و از کلاس ensemble که مربوط به الگوریتم‌های ترکیبی است، تابع RandomForestClassifier را برای دسته‌بندی مورد استفاده قرار می‌دهیم و با استفاده از تابع fit فاز آموزش را بر روی داده‌های آموزش انجام می‌دهیم و سپس با استفاده از predict، برچسب داده‌های آزمایش را معین می‌کنیم. با استفاده از دستور random_forrest test می‌توان برچسب‌ها را در کنسول مشاهده کرد.

```
def random_forrest(self, x_train, y_train, x_test):
    model = RandomForestClassifier()
    model.fit(x_train, y_train)
    y_pred = model.predict(x_test)
```

تصویر ۸: تابع دسته‌بند random_forrest

محاسبه‌ی بهترین پارامتر برای الگوریتم k-NN

در این بخش از میان kهای گفته شده در صورت پروژه -یعنی ۱ و ۵ و ۹- بهترین k را انتخاب می‌کنیم و در قسمت‌های بعدی نیز از آن استفاده می‌کنیم.

برای این کار از تابع `find_best_k` استفاده می‌کنیم. این تابع در صورتی که فلگ `print` برابر با `True` باشد، به ازای هر k از مقادیر گفته شده، تابع `knn` را با توجه به مجموعه‌ی آموزش و Validation صدا می‌زند و سپس با استفاده از خروجی آن و تابع `find_metric` که در بخش [پیاده‌سازی تابع find_metric](#) توضیح داده شده، معیارهای مختلف را به ازای هر k در خروجی چاپ می‌کند. در نهایت بهترین k را با توجه به بیشترین مقدار `accuracy` انتخاب کرده و چاپ می‌کنیم. در صورتی هم که فلگ `print` برابر `False` باشد، تنها بهترین مقدار k محاسبه می‌شود و چیزی چاپ نمی‌شود.

```
def find_best_k(self, arr, print_flag):
    max_accuracy = -1
    best_k = None
    x_train_set, y_train_set, x_validation_set, y_validation_set = self.make_knn_validation_set()
    for k in arr:
        y_pred = self.knn(x_train_set, y_train_set, x_validation_set, k)
        f1 = self.find_metric(y_validation_set, y_pred, "f1")
        precision = self.find_metric(y_validation_set, y_pred, "precision")
        recall = self.find_metric(y_validation_set, y_pred, "recall")
        accuracy = self.find_metric(y_validation_set, y_pred, "accuracy")
        if print_flag:
            print("metrics for k = ", k)
            print("f1 score = ", f1)
            print("precision = ", precision)
            print("recall = ", recall)
            print("accuracy = ", accuracy)
            print()
        if accuracy > max_accuracy:
            max_accuracy = accuracy
            best_k = k
    if print_flag:
        print("best k is: ", best_k)
        print("best accuracy score is: ", max_accuracy)
    return best_k
```

تصویر ۱۱: پیاده‌سازی تابع یافتن بهترین پارامتر k

در کنسول می‌توان با دستور `best k` خروجی این تابع را مشاهده کرد. مشاهده می‌شود که `k = 9` بهترین k بوده‌است.

```
best k
metrics for k = 1
f1 score = 0.48799999999999993
precision = 0.46564885496183206
recall = 0.5126050428168067
accuracy = 0.4732510288065844

metrics for k = 5
f1 score = 0.576923076923077
precision = 0.5319148936170213
recall = 0.6302521008403361
accuracy = 0.5473251028806584

metrics for k = 9
f1 score = 0.5643153526978054
precision = 0.5573776491803278
recall = 0.5714285714285714
accuracy = 0.5679812345679812

best k is: 9
best accuracy score is: 0.5679812345679812
```

تصویر ۱۲: خروجی دستور `best k`

محاسبه‌ی بهترین پارامتر برای الگوریتم SVM

برای پیاده‌سازی این بخش از تابع `find_best_c` استفاده شده که عیناً مشابه تابع `find_best_k` عمل می‌کند که در بخش قبل توضیح داده شد. با این تفاوت که به جای تابع `knn`، تابع `svm` صدا زده می‌شود و مقدار بهترین `C` از بین مقادیر 0.5، 1، 1.5 و 2 انتخاب می‌شود.

```
def find_best_c(self, arr, print_flag):
    max_accuracy = -1
    best_c = None
    x_train_set, y_train_set, x_validation_set, y_validation_set = self.make_validation_set()
    for c in arr:
        y_pred = self.svm(x_train_set, y_train_set, x_validation_set, c)
        f1 = self.find_metric(y_validation_set, y_pred, "f1")
        precision = self.find_metric(y_validation_set, y_pred, "precision")
        recall = self.find_metric(y_validation_set, y_pred, "recall")
        accuracy = self.find_metric(y_validation_set, y_pred, "accuracy")
        if print_flag:
            print("metrics for c = ", c)
            print("f1 score = ", f1)
            print("precision = ", precision)
            print("recall = ", recall)
            print("accuracy = ", accuracy)
            print()
        if accuracy > max_accuracy:
            max_accuracy = accuracy
            best_c = c
    if print_flag:
        print("best c is: ", best_c)
        print("best accuracy score is: ", max_accuracy)
    return best_c
```

تصویر ۱۳: تابع یافتن بهترین پارامتر `C`

با دستور `best c` می‌توان خروجی مورد نظر را مشاهده کرد که نشان می‌دهد $C = 1.5$ بهترین مقدار بوده‌است.

```
best c
metrics for c = 0.5
f1 score = 0.6254545454545455
precision = 0.5308641975308642
recall = 0.7610619469026548
accuracy = 0.5928853754940712

metrics for c = 1
f1 score = 0.5738396624472574
precision = 0.5483870967741935
recall = 0.6017699115044248
accuracy = 0.6007905138339921

metrics for c = 1.5
f1 score = 0.5907172995780591
precision = 0.5645161290322581
recall = 0.6194690265486725
accuracy = 0.616600790513834

metrics for c = 2
f1 score = 0.5022784810126581
precision = 0.5564516129032258
recall = 0.6106194690265486
accuracy = 0.6086956521739131

best c is: 1.5
best accuracy score is: 0.616600790513834
```

تصویر ۱۴: خروجی دستور `best c`

بهبود سیستم بازیابی فاز اول پروژه

در این قسمت، ابتدا با استفاده از داده‌های آموزشی هر چهار دسته‌بند را آموزش می‌دهیم. سپس داده‌های فاز ۱ را که در phase1_classifier موجودند، با استفاده از هر چهار دسته‌بند برچسب می‌زنیم و ذخیره می‌کنیم. این ذخیره‌سازی به کمک دستورات تصویر زیر انجام می‌شود.

```
naive_bayes phase1
y's saved for naive_bayes method
knn phase1
y's saved for knn method
svm phase1
y's saved for svm method
random_forrest phase1
y's saved for random_forrest method
calculate majority vote
y's saved for majority_vote_prediction method
```

تصویر ۱۵: دستورات لازم برای اجرای دسته‌بندها بر روی مستندات فاز اول

دستور calculate majority vote رای‌های مستندات را مجتمع می‌کند و بهترین برچسب را انتخاب می‌کند. نحوه‌ی کار آن در بخش تابع اجماع نظر دسته‌بندها برای تعیین برچسب هر مستند توضیح داده می‌شود. سپس این برچسب‌ها را در فایل ذخیره می‌کند.

حال می‌توانیم با توجه به ورودی کاربر که ۱ یا ۱- است، مستندات مرتبط با آن دسته را در خروجی به کاربر نمایش دهیم. به این صورت که پس از فیلتر کردن مستندات فاز اول بر اساس دسته، مطابق همان چیزی که در فاز اول پیاده‌سازی شده‌است، مستندات را بر اساس معیار ltc-lnc مرتب‌سازی می‌کنیم و به کاربر نمایش می‌دهیم. در ادامه توابع این بخش را توضیح می‌دهیم.

classifier.py	10.7 kB	14:11
data	4 items	Yesterday
lr_system.py	46.4 kB	14:29
knn_y_prediction	8.8 kB	14:21
main.py	19.3 kB	13:57
majority_vote_prediction_y_prediction	10.5 kB	14:24
naive_bayes_y_prediction	8.7 kB	14:18
phase1_classifier_data	470.2 MB	13:30
phase2_command	481 bytes	14:16
__pycache__	2 items	14:29
random_forrest_y_prediction	20.6 kB	14:24
svm_y_prediction	20.6 kB	14:24
test_classifier_data	248.1 MB	13:30

تصویر ۱۶: فایل‌های جانبی ذخیره شده که برچسب‌های هر دسته‌بندی را نگه می‌دارند.

تابع اجماع نظر دسته‌بندها برای تعیین برجسب هر مستند

در این قسمت، ابتدا برجسب‌های ذخیره‌سازی شده برای هر دسته‌بند را بارگذاری می‌کنیم و سپس برای هر مستند نظر اجماع دسته‌بندها را به عنوان برجسب آن مستند در نظر می‌گیریم.

نکته‌ای که باید به آن توجه کرد این است که چهار دسته‌بند داریم و لذا ممکن است دو دسته‌بند نظر به برجسب ۱ داشته باشند و دو تای دیگر نظر به برجسب ۱- در این حالت برجسبی که دسته‌بند Random Forest برای مستند انتخاب کرده‌است به عنوان نتیجه‌ی نهایی در نظر گرفته می‌شود، زیرا با آن به دقت بالاتری می‌رسیدیم. همان‌طور که گفته شد، این اجماع نظر به کمک دستور calculate majority vote انجام می‌گیرد.

جستجو بر اساس دسته

تابع این بخش، phase1_query است که در IRSystem طراحی شده‌است. ابتدا نظر جمعی دسته‌بندها را لود می‌کنیم و از آن برای برجسب زدن هر مستند فاز اول استفاده می‌کنیم. سپس مانند فاز قبلی پروژه عمل می‌کنیم، با این تفاوت که جستجو را در دسته‌ی مشخص شده انجام می‌دهیم.

در این قسمت برای جستجو با انتخاب دسته‌ی مورد نظر دستور phase1 query در کنسول زده می‌شود. سپس از کاربر می‌خواهیم دسته‌ی مورد نظر را انتخاب کند و بعد از آن مستندات را با توجه به ورودی کاربر فیلتر می‌کنیم. پس از آن کاربر می‌بایست پرمسان خود را وارد کند و پس از تصحیح پرمسان و رتبه‌بندی مطابق فاز قبل، نتایج به کاربر نشان داده می‌شود.

نمونه‌هایی از اجرای این بخش در ادامه دیده می‌شود.

```
prepare english
create positional english
creation was successful
create bigram english
creation was successful
phase1 query
Please Enter Zone Of Search(1 -> Most View , -1 -> Less View): 1
Enter Your Query: dianna cohen
no spell correction needed!
document 2054: [['alzheimer', 'not', 'normal', 'age', 'cure'], ['than', 'million', 'people', 'worldwide', 'suffer', 'alzheimer', 'diseases', 'number', 'expect', 'increases', 'drastic', 'come', 'year', 'no', 'real', 'progress',
lto-lnc score: 0.29602230789457598
document 2167: [['get', 'back', 'work', 'after', 'career', 'break'], ['if', 'you', 'taken', 'career', 'break', 'now', 'look', 'return', 'workforce', 'would', 'consider', 'take', 'internship', 'career', 'reentry', 'exper
lto-lnc score: 0.1899854696322041
document 1562: [['argument', 'sake'], ['do', 'argue', 'outreason', 'opponent', 'prove', 'them', 'wrong', 'most', 'all', 'win', 'right', 'philosopher', 'daniel', 'h', 'cohen', 'show', 'most', 'common', 'form', 'argument', 'w
lto-lnc score: 0.16529085709750133
phase1 query
Please Enter Zone Of Search(1 -> Most View , -1 -> Less View): -1
Enter Your Query: dianna cohen
no spell correction needed!
document 795: [['tough', 'truth', 'plastic', 'pollut'], ['artist', 'dianna', 'cohen', 'share', 'some', 'tough', 'truth', 'plastic', 'pollut', 'ocean', 'live', 'some', 'thought', 'free', 'ourselves', 'plastic', 'gyre']]
lto-lnc score: 0.4754492865822986
```

تصویر ۱۷: اجرای دستور phase1 query برای هر دو دسته با پرمسان dianna cohen

```
phase1 query
Please Enter Zone Of Search(1 -> Most View ,-1 -> Less View): 1
Enter Your Query: penicillin
no spell correction needed!
document 2804: [{"do", "do", "when", "antibiot", "dont", "work", "ani"}, {"penicillin", "chang", "everyth", "infect", "had", "previous", "kill", "were", "sudden", "quick", "curabl", "yet", "maryn", "mckenna", "share"},
lrc-lnc score: 0.24031126697043745
phase1 query
Please Enter Zone Of Search(1 -> Most View ,-1 -> Less View): -1
Enter Your Query: penicillin
no spell correction needed!
Query Not Found in Your Zone
```

تصویر ۱۸: اجرای دستور phase1 query برای هر دو دسته با پرسمان penicillin

ارزیابی نهایی

در این بخش ابتدا تابع `find_metric` را پیاده‌سازی می‌کنیم که با توجه به رشته‌ی ورودی که همان معیار مورد نظر است، مقدار آن معیار را با توجه به دو ورودی دیگر که دو لیست از مقادیر واقعی و مقادیر پیش‌بینی شده هستند، خروجی می‌دهد. سپس برای هر کدام از دسته‌بندها معیارهای خواسته شده را محاسبه می‌کنیم که در ادامه توضیح داده می‌شوند.

پیاده‌سازی تابع `find_metric`

تابع `find_metric` سه ورودی به نام‌های `y_test`، `y_pred` و `metric` دارد که:

- ورودی `y_test` شامل گروه‌های واقعی مستندات آزمایش (`test.csv`) است.
- ورودی `y_pred` شامل گروه‌های پیش‌بینی شده‌ی مستندات آزمایش است.
- ورودی `metric` نیز معیار ارزیابی را مشخص می‌کند که یک رشته است و مقدار آن برابر با یکی از مقادیر `accuracy`، `precision` یا `recall` است.

نحوه‌ی عملکرد این تابع نیز به این صورت است که با توجه به ورودی‌ها تعداد `True Positive`، `True Negative`، `False Positive` و `False Negative` را به دست می‌آورد. سپس با توجه به فرمول‌های اسلایدها، معیار خواسته شده را خروجی می‌دهد.

معیارهای ارزیابی برای Naïve Bayes

در این قسمت، با وارد کردن دستور `naïve_bayes [metric]` در کنسول، می‌توان مقدار معیار ورودی را برای دسته‌بند Naïve-Bayes مشاهده کرد.

```
accuracy naive_bayes
accuracy is: 0.6509803921568628
precision naive_bayes
precision is: 0.6159420289855072
recall naive_bayes
recall is: 0.7024793388429752
f1 naive_bayes
f1 is: 0.6563706563706564
```

تصویر ۱۹: مقدار معیارهای ارزیابی برای دسته‌بند Naïve Bayes

معیارهای ارزیابی برای k-NN

با وارد کردن دستور `knn k [metric]` می توان مقادیر معیار ورودی را برای دسته‌بند `k-NN` مشاهده کرد. با توجه به این که در این بخش معیارها برای بهترین `k` خواسته شده بود، `k` را برابر با 9 قرار می‌دهیم.

```
accuracy knn 9
accuracy is:  0.5647058823529412
precision knn 9
precision is:  0.5384615384615384
recall knn 9
recall is:  0.5785123966942148
f1 knn 9
f1 is:  0.5577689243027888
```

تصویر ۲۰: مقدار معیارهای ارزیابی برای دسته‌بند `k-NN` ($k = 9$)

معیارهای ارزیابی برای SVM

دستور `svm c [metric]` را در کنسول وارد می‌کنیم که با توجه به صورت پروژه، مقدار `c` را برابر با بهترین `C`، یعنی 1.5 قرار می‌دهیم.

```
accuracy svm 1.5
accuracy is:  0.6666666666666666
precision svm 1.5
precision is:  0.6666666666666666
recall svm 1.5
recall is:  0.5950413223140496
f1 svm 1.5
f1 is:  0.62882096069869
```

تصویر ۲۱: مقدار معیارهای ارزیابی برای دسته‌بند `SVM` ($C = 1.5$)

معیارهای ارزیابی برای Random Forest

از دستور `random_forrest [metric]` استفاده می‌کنیم که مقدار معیار ورودی را تحت دسته‌بندی `Random Forest` محاسبه می‌کند.

```
accuracy random_forrest
accuracy is: 0.6431372549019608
precision random_forrest
precision is: 0.6728971962616822
recall random_forrest
recall is: 0.628099173553719
f1 random_forrest
f1 is: 0.6419753086419753
```

تصویر ۲۲: مقدار معیارهای ارزیابی برای دسته‌بند Random Forest

نتیجه‌گیری نهایی معیارهای ارزیابی

با توجه به تصاویر ۱۹، ۲۰، ۲۱ و ۲۲ می‌توان نتیجه گرفت که:

- دسته‌بند SVM بیشترین accuracy را داشته‌است.
- دسته‌بند Random Forest بیشترین مقدار precision را حاصل کرده‌است.
- دسته‌بند Naïve Bayes بیشترین مقدار F1 و recall را داشته‌است.
- معیارهای ارزیابی دسته‌بند k-NN نسبت به سایر دسته‌بندها پایین‌تر بوده‌است.

نحوه‌ی تقسیم وظایف

وظایف اختصاص یافته به هر فرد به شرح زیر بود:

نیما جمالی

- ۱- پیش‌پردازش داده‌ها و پیاده‌سازی روش ntn
- ۲- ساخت دو مدل فضای برداری و توابع مربوط به آنها
- ۳- پیاده‌سازی دسته‌بند k-NN و توابع جانبی آن
- ۴- پیاده‌سازی تابع محاسبه‌ی بهترین پارامتر k و ساختن مجموعه‌ی Validation

سپهر فعلی

- ۱- طراحی دسته‌بند Naïve-Bayes و توابع مربوط به آن
- ۲- طراحی توابع محاسبه‌ی معیارهای ارزیابی
- ۳- مقایسه‌ی معیارهای ارزیابی برای دسته‌بندها

سینا کاظمی

- ۱- طراحی دسته‌بندهای SVM و Random Forest
- ۲- پیاده‌سازی تابع محاسبه‌ی بهترین پارامتر C برای دسته‌بند SVM
- ۳- طراحی تابع اجماع نظر دسته‌بندها
- ۴- طراحی تابع پاسخ پرسمان، بسته به دسته‌ی ورودی

مراجع

- [1] <https://scikit-learn.org/stable/modules/svm.html>
- [2] <https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestClassifier.html>